

Kolokwium z wykładu MSI

Pytanie 0: Walidacja krzyżowa (cross-validation) – na czym polega, gdzie i po co się ją stosuje

Na czym polega:

Polega na podziale dostępnego zbioru danych na K równych, rozłącznych części (podzbiorów), zwanych „fałdami” (*folds*). Proces uczenia i testowania powtarzany jest K razy. W każdej iteracji podzbiór numer i służy jako dane testowe (walidacyjne), a pozostałe $K-1$ podzbiorów łączy się i wykorzystuje jako dane treningowe. Ostateczny wynik wydajności modelu to średnia z wyników uzyskanych we wszystkich K iteracjach.

Wzór formalny:

Ostateczną ocenę jakości modelu (E) oblicza się jako średnią ze wskaźników błędu (lub ogólnie miar jakości, np. dokładności) uzyskanych w każdej z K iteracji:

$$E = \frac{1}{K} \sum_{i=1}^K E_i$$

Gdzie:

- K – całkowita liczba fałdów (podzbiorów), [PDF](#)
- E_i – błąd (lub wartość metryki) uzyskany w i -tej iteracji, gdy i -ty fałd był zbiorem testowym.

Gdzie się ją stosuje:

- W uczeniu maszynowym podczas trenowania modeli klasyfikacji i regresji.
- Przy optymalizacji hiperparametrów (np. dobór głębokości drzewa, liczby sąsiadów w k-NN).
- W sytuacjach, gdy dysponujemy stosunkowo małym zbiorem danych i tradycyjny podział na train/test byłby nieefektywny.

Po co się ją stosuje:

- Wiarygodna ocena: Pozwala uzyskać stabilną, nieobciążoną ocenę zdolności generalizacji modelu na nowych, nieznanymi danych.

- Przeciwdziałanie przeuczeniu (*overfitting*): Gwarantuje, że każdy przykład ze zbioru danych znajdzie się dokładnie raz w zbiorze testowym i K-1 razy w zbiorze treningowym.

Pytanie 3: Zasada działania sieci neuronowej typu perceptrona wielowarstwowego (MLP)

Zasada działania MLP:

MLP to sieć jednokierunkowa (feedforward), składająca się z warstwy wejściowej, jednej lub kilku warstw ukrytych oraz warstwy wyjściowej. Każdy neuron w warstwie wyższej oblicza sumę ważoną sygnałów z warstwy poprzedniej, dodaje wyraz wolny (bias) i przepuszcza wynik przez nieliniową funkcję aktywacji (f).

Wykres:



Wzór (przejście w przód - forward pass):

Dla pojedynczego neuronu:

$$y = f \left(\sum_{i=1}^n w_i x_i + b \right)$$

Gdzie: x_i – wejścia, w_i – wagi, b – bias, f – funkcja aktywacji (np. ReLU, sigmoidalna).

Pytanie 8: Operatory krzyżowania w algorytmach genetycznych w zagadnieniach uporządkowania ciągu niepowtarzalnych wartości (np. problem komiwojażera - TSP)

W problemach takich jak TSP, chromosom jest permutacją (np. kolejnością miast: [1, 3, 2, 4]). Klasyczne krzyżowanie (np. jednopunktowe) mogłoby stworzyć potomka z powtórzonymi miastami i brakującymi punktami (np. [1, 3, 3, 4] – co jest niepoprawną trasą). Dlatego stosuje się specjalne operatory zachowujące unikalność.

Jednym z najpopularniejszych jest krzyżowanie PMX (Partial-Mapped Crossover).

Wykres / Schemat działania PMX:

Plaintext

Rodzic 1: [1 | 2 3 4 | 5 6]

Rodzic 2: [5 | 4 6 2 | 1 3]

^-----^ <- Wybrane losowo sekcje (wycinki)

Krok 1: Przepisanie wycinka z Rodzica 1 do Potomka 1 i stworzenie mapowania:

Potomek 1: [_ | 2 3 4 | _ _] (Mapowanie: 2<->4, 3<->6, 4<->2)

Krok 2: Przepisanie pozostałych elementów z Rodzica 2. Jeśli element już jest, używamy mapowania (np. '4' z R2 mapuje się na '2', a '2' dalej na '4'... ostatecznie zapobiega to duplikatom).

Potomek 1: [5 | 2 3 4 | 1 6]

Wzór / Reguła formalna: Nie istnieje jeden prosty wzór matematyczny, operację opisuje się algorytmicznie jako relację mapowania pozycji:

Jeżeli $P_1[i] \in \text{wycinek}$, to $P_2[i] \rightarrow P_1[i]$

Dla każdego elementu spoza wycinka $x = P_2[j]$:

$$Potomek[j] = \begin{cases} x & \text{jeśli } x \notin \text{wycinek} \\ map(x) & \text{jeśli } x \in \text{wycinek} \end{cases}$$

Komentarz: Operatory takie jak PMX, OX (Order Crossover) czy CX (Cycle Crossover) gwarantują, że każdy gen (miasto/klawisz) pojawi się w nowo powstałym chromosomie dokładnie jeden raz. Dzięki temu wygenerowane rozwiązanie potomne jest od razu poprawne (dopuszczalne) i nie wymaga stosowania dodatkowych, kosztownych funkcji naprawczych.