


Sztuczna inteligencja – sprawozdanie


1. Wstęp

To sprawozdanie prezentuje analizę i porównanie różnych metod zespołowych (Ensemble Learning) zaimplementowanych w bibliotece Scikit-Learn. Celem było ocenienie ich efektywności w klasyfikacji jakości wina, używając zbioru danych 'winequality-red.csv'. Porównano pojedyncze drzewo decyzyjne z czterema metodami zespołowymi: Bagging, Random Forest, Voting oraz Stacking.

1.1. Eksploracyjna Analiza Danych (EDA)

Przed przystąpieniem do budowy modeli, przeprowadzono wstępną analizę danych. Wykres rozkładu zmiennej docelowej (quality) pokazał, że większość win ma oceny 5 lub 6, co wskazuje na niezbalansowany charakter danych. Z kolei macierz korelacji pozwoliła zidentyfikować kluczowe zależności między cechami a jakością wina. Zauważono, że cechy takie jak 'alcohol' i 'sulphates' wykazują pozytywną korelację z jakością, natomiast 'volatile acidity' i 'pH' korelują negatywnie. Te obserwacje są cenne dla zrozumienia danych i potencjalnych kierunków optymalizacji modeli.





2. Metodologia

- **Dane:** Załadowano zbiór 'winequality-red.csv', używając kolumny 'quality' jako zmiennej docelowej. Dane podzielono na zbiór treningowy (75%) i testowy (25%).
- **Modele bazowe:** Wykorzystano drzewo decyzyjne (DecisionTreeClassifier), regresję logistyczną (LogisticRegression) oraz maszynę wektorów nośnych (SVC).
- **Metody zespołowe:** Zaimplementowano i przetestowano:
 - **Bagging:** Z DecisionTreeClassifier jako estymatorem bazowym.
 - **Random Forest:** Silna odmiana Baggingu.
 - **Voting:** Łączący LogisticRegression, DecisionTreeClassifier i SVC w trybie 'soft' voting.
 - **Stacking:** Używa RandomForestClassifier, SVC i LogisticRegression jako estymatorów bazowych oraz LogisticRegression jako estymatora końcowego.
- **Ocena:** Wszystkie modele wytrenowano i oceniono na zbiorze testowym pod kątem dokładności (accuracy). Ze względu na niezbalansowanie klas

zidentyfikowane w punkcie 1.1, dokładność traktowana jest jako metryka bazowa wyjściowa do dalszych eksperymentów.


2.1. Skalowanie Danych (Data Scaling)

Dodatkowo, w celu poprawy stabilności i wydajności modeli wrażliwych na skalę cech (np. regresja logistyczna, maszyny wektorów nośnych), zastosowano standaryzację danych za pomocą StandardScaler. Proces ten polega na przeskalowaniu wartości cech tak, aby miały średnią równą 0 i odchylenie standardowe równe 1. Dzięki temu wszystkie cechy mają porównywalny wpływ na proces uczenia modelu, co zapobiega dominacji cech o większych wartościach liczbowych.

3. Wyniki i Analiza Porównawcza

Poniższa tabela oraz wykres przedstawiają porównanie dokładności (accuracy) każdego z wytrenowanych modeli na zbiorze testowym, zarówno na oryginalnych, jak i przeskalowanych danych:

Model	Dokładność – Dane Oryginalne (Original Data)	Dokładność – Dane Przeskalowane (Scaled Data)
Single Tree	0.5375	0.5375
Random Forest	0.6700	0.6775
Bagging	0.5900	0.5900
Voting	0.5725	0.5950
Stacking	0.6700	0.6850



Powyższy wykres słupkowy przedstawia końcowe porównanie dokładności (accuracy) wszystkich testowanych algorytmów. Wizualizacja jednoznacznie potwierdza przewagę metod zespołowych nad pojedynczym drzewem decyzyjnym, które osiągnęło najniższy wynik (0.5375). Najwyższą wydajnością wykazał się model Stacking, osiągając dokładność 0.6850, tuż przed algorytmem Random Forest (0.6775). Wykres ten udowadnia, że zaawansowane łączenie modeli (zarówno homogeniczne w Random Forest, jak i heterogeniczne w Stacking) przynosi wyraźny wzrost stabilności i precyzji predykcji na analizowanym zbiorze danych.

4. Dogłębna Analiza i Wnioski



Analizując przedstawione wyniki, można zaobserwować kilka kluczowych zależności i wyciągnąć istotne wnioski:

- Wpływ Skalowania na Modele Liniowe:** Ostrzeżenia o braku konwergencji dla LogisticRegression na oryginalnych danych potwierdziły potrzebę skalowania. Po zastosowaniu StandardScaler, modele wykorzystujące regresję logistyczną (szczególnie Voting i Stacking, gdzie LogisticRegression jest używana jako estymator bazowy lub końcowy) odnotowały poprawę dokładności i eliminację problemów z konwergencją. To podkreśla, jak krytyczne jest skalowanie dla algorytmów opartych na odległościach lub gradientach.
- Zachowanie Modeli Drzewiastych:** Modele oparte na drzewach decyzyjnych, takie jak Single Tree i Bagging (z drzewem jako

estymatorem bazowym), są zazwyczaj mniej wrażliwe na skalowanie cech. Ich wydajność nie uległa zmianie po przeskalowaniu danych, co jest zgodne z teorią, gdyż algorytmy te opierają się na podziałach przestrzeni danych, a nie na miarach odległości.

3. **Dominacja Metod Zespołowych:** Metody zespołowe (Random Forest, Bagging, Voting, Stacking) konsekwentnie przewyższały pojedyncze drzewo decyzyjne. Potwierdza to ich skuteczność w agregowaniu decyzji wielu słabych uczących się w celu zbudowania silniejszego i bardziej stabilnego modelu.
4. **Najlepsze Wyniki:** Random Forest i Stacking utrzymują się jako najlepiej działające modele, wykazując największą dokładność. Stacking okazał się najlepszym modelem w całym eksperymencie z dokładnością wynoszącą 0.6850, nieznacznie wyprzedzając Random Forest. Wynika to z faktu, że Stacking potrafi efektywnie połączyć moc różnych modeli bazowych, optymalizując ich wkład za pomocą meta-klasyfikatora.
5. **Ogólna Trudność Klasyfikacji:** Niskie ogólne wartości dokładności (w przedziale około 60-70%) sugerują, że klasyfikacja jakości wina na podstawie tego zbioru danych jest zadaniem trudnym. Może to wynikać ze złożoności i szumu w rzeczywistych danych, a także z subiektywnego charakteru ludzkiej oceny jakości wina.

4.1. Analiza Istotności Cech (Feature Importance) – Porównanie Modelu Bazowego i Zespołowego



Równoległe zestawienie istotności cech dla pojedynczego drzewa decyzyjnego oraz lasu losowego (Random Forest) dostarcza kluczowych wniosków z punktu widzenia teorii uczenia maszynowego:

- **Pojedyncze Drzewo Decyzyjne:** Wykazuje tendencję do nadmiernej koncentracji na jednej zmiennej. Cecha alcohol całkowicie zdominowała model, osiągając współczynnik istotności na poziomie aż 0.50. Sprawia to, że model bazowy staje się niestabilny, wysoce podatny na zjawisko przeuczenia (overfitting) i ignoruje subtelniejsze zależności chemiczne.
- **Random Forest:** Dzięki wbudowanemu mechanizmowi losowania podzbiorów cech podczas tworzenia węzłów, model zespołowy dokonał znacznie lepszej dywersyfikacji wag. Choć zawartość alkoholu (alcohol) pozostaje najistotniejszym czynnikiem (około 0.15), algorytm skutecznie i równomiernie włączył do procesu decyzyjnego inne parametry, takie jak siarczany (sulphates), całkowity dwutlenek siarki (total sulfur dioxide) oraz kwasowość lotną (volatile acidity).

Ta zasadnicza różnica w architekturze wewnętrznej w pełni wyjaśnia, dlaczego Random Forest osiągnął na danych przeskalowanych wynik o ponad 14 punktów procentowych wyższy niż pojedyncze drzewo (0.6775 vs 0.5375). Agregacja wielu zróżnicowanych struktur pozwoliła na skuteczną redukcję błędu wariancji i zbudowanie odporniejszego klasyfikatora. Wyniki te są również całkowicie spójne z analizą korelacji EDA przeprowadzoną na wstępie prac.

5. Rekomendacje i Dalsze Kroki

Na podstawie przeprowadzonej analizy, rekomenduje się następujące działania w celu dalszej optymalizacji:

- **Dostrajanie Hiperparametrów:** Zastosowanie zaawansowanych technik dostrajania, takich jak GridSearchCV lub RandomizedSearchCV, aby znaleźć optymalne konfiguracje dla wszystkich modeli, ze szczególnym uwzględnieniem tych o największym potencjale (Random Forest, Stacking).
- **Inżynieria Cech (Feature Engineering):** Stworzenie nowych, bardziej informatywnych cech z istniejących, które mogą lepiej oddawać złożone zależności chemiczne w danych dotyczących wina.
- **Zwiększenie Złożoności Modeli Bazowych:** Eksperymentowanie z bardziej złożonymi estymatorami bazowymi w ramach Voting i Stacking

lub zmianą konfiguracji obecnych (np. testowanie różnych wartości parametru `max_depth` dla `DecisionTreeClassifier`).

- **Analiza Błędów i Macierzy Pomyłek:** Dokładna analiza błędów popełnianych przez najlepsze modele, co pozwoli ujawnić, które klasy winą są najtrudniejsze do poprawnego przewidzenia.
- **Ocena Innych Metryk:** Rozważenie wdrożenia metryk takich jak precyzja (precision), czułość (recall) oraz F1-score. Dostarczą one znacznie bardziej szczegółowego obrazu wydajności modeli, co jest kluczowe w przypadku analizowanego tutaj zbioru o niezbalansowanych klasach.